






# Doğrusal Bağlantı

Hesaplamalı Matematik I - Özgür Martin

# Hatırlatma: Öğrenme Problemi



# Öğrenme Problemi



# Doğrusal Bağlantı (Linear Regression)

Güdümlü öğrenmeye basit bir yaklaşım

*reklam.xlsx*

TV	radyo	gazete	satış
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9
8.7	48.9	75	7.2
57.5	32.8	23.5	11.8
120.2	19.6	11.6	13.2

- Reklam bütçesi ile satış değerleri arasında ilişki var mı?
- Reklam bütçesi ile satış değerleri arasında ilişki ne kadar güçlü?
- Satışa hangi medyalar etki ediyor?
- Her bir medyanın satışa etkisini ne kadar hassas tahmin edebiliriz?
- Gelecekteki satışları ne kadar hassas kestirebiliriz?
- Değerler arasındaki ilişki doğrusal mı?

# Basit Doğrusal Bağlanım

Hatırlatma:

$$Y = f(X) + \epsilon \xrightarrow{\text{yaklaşık?}} \hat{Y} = \hat{f}(X)$$

$$Y \approx \hat{f}(X)$$


Basit Bağlanım

$$Y \approx \beta_0 + \beta_1 X$$

$$\text{satis} \approx \beta_0 + \beta_1 \text{TV}$$

$$Y \approx \beta_0 + \beta_1 X \quad (\text{satış} \approx \beta_0 + \beta_1 \text{TV})$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$



?

eğitim verisi

$$\{(x_i, y_i) : 1, \dots, n\}$$

$$y_i \approx \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\hat{y}_i}, \quad i = 1, \dots, n$$


$$y_i \approx \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\hat{y}_i}, \quad i = 1, \dots, n$$

$$e_i = y_i - \hat{y}_i \quad \text{i. kalıntı (ith residual)}$$

## Kalıntı Kareler Toplamı (Residual Sum of Squares)

$$\text{KKT} = e_1^2 + e_2^2 + \cdots + e_n^2$$

(Amaç: Bu toplamı minimize eden  $\hat{\beta}_0$  ve  $\hat{\beta}_1$  değerlerini bulalım)





## En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{KKT} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Çözüm:

Dışbükey Fonksiyon



Çözüm:

$$\frac{\partial(\text{KKT})}{\partial \hat{\beta}_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i), \quad \frac{\partial(\text{KKT})}{\partial \hat{\beta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i$$

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i, \quad \hat{\beta}_0 \sum_{i=1}^n x_i + \hat{\beta}_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Burada  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  ve  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$SST = SSR + SSE$$

Total Sum of Squares)

Regression Sum of Squares

Error Sum of Squares

$$SST = \sum (y_i - \bar{y})^2$$

$$SSR = \sum (\hat{y}_i - \bar{y})^2$$


$$SSE = \sum (y_i - \hat{y}_i)^2$$

where:

$\bar{y}$  =  $y$  değerlerinin ortalaması

$y_i$  =  $y$ 'lerin gerçek değerleri

$\hat{y}_i$  = verilmiş  $x_i$  için  $y$ 'lerin model tarafından tahmin edilmiş değeri



# R-kare (R-squared) veya $R^2$

$y_i$  değerlerindeki değişimin ne kadarının modelimiz tarafından açıkladığını ölçer!

$$R^2 = \frac{SSR}{SST} = \frac{\text{regression sum of squares}}{\text{total sum of squares}}$$

Not:

$$0 \leq R^2 \leq 1$$

Veriyi şu fonksiyondan üretelim:  $Y = 2 + 3X + \epsilon$

$$\{(x_i, y_i): i = 1, \dots, n\}$$


Üretilmiş veri seti

Rastgele hata

Kırmızı doğru: Gerçek ilişki

$$f(X) = 2 + 3X$$

Mavi doğru:  $f(X)$  fonksiyonuna EKK yöntemi ile yaklaşım



Yeni veri üretip ek küçük kareler (EKK) yöntemi ile yeni veriye  
karşılık gelen bağlanım doğrularını bulalım:


$$\{(x_i^{(1)}, y_i^{(1)}) : i = 1, \dots, n\} \xrightarrow{\text{EKK}} \hat{\beta}_0^{(1)}, \hat{\beta}_1^{(1)}$$

$$\{(x_i^{(2)}, y_i^{(2)}) : i = 1, \dots, n\} \xrightarrow{\text{EKK}} \hat{\beta}_0^{(2)}, \hat{\beta}_1^{(2)}$$

⋮

$$\{(x_i^{(N)}, y_i^{(N)}) : i = 1, \dots, n\} \xrightarrow{\text{EKK}} \hat{\beta}_0^{(N)}, \hat{\beta}_1^{(N)}$$



Veri kümesi değişikçe bağlanım doğrusu da değişiyor!



## Hatırlatma:

Hipotez Kümesi:

$$\{\beta_0 + \beta_1 X: \beta_0, \beta_1 \in \mathbb{R}\}$$



# Basit Doğrusal Bağlanım Örneği

Reklam verisi: *reklam.xlsx*

TV	radyo	gazete	satış
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9
8.7	48.9	75	7.2
57.5	32.8	23.5	11.8
120.2	19.6	11.6	13.2

$$\text{satış} \approx \beta_0 + \beta_1 \text{TV}$$



# Basit Doğrusal Bağlanım Örneği

[1]

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn import datasets, linear_model
from sklearn.metrics import mean_squared_error, r2_score
```



```
reklam_verisi = pd.read_excel('/content/drive/My Drive/Colab Data/reklam.xlsx')
reklam_verisi.head()
```



	TV	radyo	gazete	satış
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	9.3
3	151.5	41.3	58.5	18.5
4	180.8	10.8	58.4	12.9



# Basit Doğrusal Bağlanım Örneği

```
▶ x = np.array(reklam_verisi['TV']).reshape(-1, 1)
y = np.array(reklam_verisi['satış'])

regr = linear_model.LinearRegression(fit_intercept =True)

regr.fit(x, y)

y_tahmin = regr.predict(x)
```

```
▶ print('y =', regr.intercept_, ' + ', regr.coef_[0], '* x')
print('Ortalama kare hata: %.2f' % mean_squared_error(y, y_tahmin))
print('R-kare: %.2f' % r2_score(y, y_tahmin))
```

```
⇨ y = 7.032593549127695 + 0.04753664043301975 * x
Ortalama kare hata: 10.51
R-kare: 0.61
```

$$= \frac{KKT}{n}$$

# Basit Doğrusal Bağlanım Örneği

$$\text{satış} \approx \beta_0 + \beta_1 \text{TV}$$


$$\text{satış} \approx 7.0325 + 0.0475 \text{ TV}$$

Televizyona verilecek her **1000 \$'lık** fazladan reklam için yaklaşık **47** tane fazladan ürün satılmasını bekliyoruz.

# Basit Doğrusal Bağlanım Örneği

```
▶ plt.scatter(x, y, color='red')
  plt.plot(x, y_tahmin, color='blue', linewidth=3)

  plt.show()
```



# Doğrusal Bağlanımdan Beklentilerimiz

Kestirim

$$x_0 = \begin{bmatrix} \circ \\ \vdots \\ \circ \end{bmatrix} \longrightarrow y_0 = ?$$

Ne?

EVET

Çıkarım

$$x_0 = \begin{bmatrix} \bullet \\ \vdots \\ \bullet \end{bmatrix} \xrightarrow{?} y_0$$

Nasıl?

EVET