



Optimizasyon 2

Hesaplamalı Matematik I - Özgür Martin

Kısıtsız Çok Değişkenli Optimizasyon


Dışbükey $f: \mathbb{R}^n \rightarrow \mathbb{R}$ fonksiyonunun birinci dereceden kısmi türevleri var ve sürekli olsun

Gradyan vektörü:

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$$



Hatırlatma: f fonksiyonun bir $x \in \mathbb{R}^n$ noktasında en hızlı azaldığı yön gradyanın ter yönündür, yani $-\nabla f(x)$.

Amaç: Lokal minimumlardan bir tanesine ulaşmak. Bu noktalarda $\nabla f(x) = 0$.



Hatırlatma: Dışbükey fonksiyonlarda tek bir lokal minimum var. Bu aynı zamanda global minimum.

Dışbükey Fonksiyon




Gradyan İnişi Yöntemi (Tek Değişken)

$f: \mathbb{R} \rightarrow \mathbb{R}$ fonksiyonu için $f'(x) = 0$ olan x noktasını arıyoruz. Öğrenme hızı c 'yi türevin mutlak değeri ile çarpıp kullanalım!

Gradyan İnişi Yöntemi

1. Herhangi bir x noktasından başla.
2. Bir öğrenme hızı c seç.
3. $x = x - c f'(x)$
4. $|f'(x)|$ yeterince küçük olana kadar devam et.




Gradyan İnişi Yöntemi (Çok Değişken)


Dışbükey, bütün kısmi türevleri var ve sürekli olan bir $f: \mathbb{R}^n \rightarrow \mathbb{R}$ fonksiyonu için $\nabla f(x) = 0$ eşitliğini sağlayan $x \in \mathbb{R}^n$ noktasını arıyoruz.

Gradyan İnişi Yöntemi


1. Herhangi bir $x \in \mathbb{R}^n$ noktasından başla.
2. Bir öğrenme hızı c seç.
3. $x = x - c \nabla f(x)$
4. $\|\nabla f(x)\|$ yeterince küçük olana kadar devam et.




Gradyan İnişi Yöntemi (Çok Değişken)




Gradyan İnişi Yöntemi (Çok Değişken)



Gradyan İnişi Yöntemi (Çok Değişken)



Gradyan İnişi Yöntemi (Çok Değişken)



Uygulama: Doğrusal Bağlanım

$$y_i \approx \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\hat{y}_i}, \quad i = 1, \dots, n$$

$$e_i = y_i - \hat{y}_i \quad i. \text{ kalıntı (ith residual)}$$

Kalıntı Kareler Toplamı (Residual Sum of Squares)

$$\text{KKT} = e_1^2 + e_2^2 + \cdots + e_n^2$$

(Amaç: Bu toplamı minimize eden $\hat{\beta}_0$ ve $\hat{\beta}_1$ değerlerini bulalım)

En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{KKT} = \min_{\hat{\beta}_0, \hat{\beta}_1} (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Minimize edilmek istenen fonksiyon basit (doğrusal) olduğundan analitik bir çözüm bulabildik:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Burada $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ve $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Şimdi analitik çözüm yerine **gradian iniş yöntemi ile** minimizasyon problemini çözelim?

Gradyan İniş İle Çözüm

Problem:


$$\min_{(\hat{\beta}_0, \hat{\beta}_1) \in \mathbb{R}^2} f(\hat{\beta}_0, \hat{\beta}_1)$$

En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} KKT = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Cözüm:

Dışbükey Fonksiyon



Problem:

$$\min_{(\hat{\beta}_0, \hat{\beta}_1) \in \mathbb{R}^2} f(\hat{\beta}_0, \hat{\beta}_1)$$

$$f(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

$$\begin{aligned}\nabla f(\hat{\beta}_0, \hat{\beta}_1) &= \begin{bmatrix} \frac{\partial f}{\partial \hat{\beta}_0} \\ \frac{\partial f}{\partial \hat{\beta}_1} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n \frac{\partial}{\partial \hat{\beta}_0} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \\ \sum_{i=1}^n \frac{\partial}{\partial \hat{\beta}_1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n -2(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \\ \sum_{i=1}^n -2x_i(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \end{bmatrix} \\ &= \begin{bmatrix} -2 \sum_{i=1}^n y_i + 2n\hat{\beta}_0 + 2\hat{\beta}_1 \sum_{i=1}^n x_i \\ -2 \sum_{i=1}^n x_i y_i + 2\hat{\beta}_0 \sum_{i=1}^n x_i + 2\hat{\beta}_1 \sum_{i=1}^n x_i^2 \end{bmatrix}\end{aligned}$$